

# Wykorzystanie LLM do Automatycznej Analizy Infrastruktury drogowej

Generowanie i analiza grafów sieci liniowych z użyciem dużych modeli  
językowych i baz grafowych Neo4j

---

# Sekcja 1: Wprowadzenie i Kontekst

Definicja problemu, cele oraz fundamenty modelu danych

# | Kontekst i Wyzwania Badawcze

## Tradycyjne Metody

Modelowanie infrastruktury (sieci drogowe, wodociągowe) opiera się obecnie na manualnej digitalizacji. Jest to proces czasochłonny, kosztowny i obarczony wysokim ryzykiem błędów ludzkich.

## Potencjał Technologii

Duże Modele Językowe (LLM) oferują nowe możliwości w automatycznej ekstrakcji informacji z nieustrukturyzowanych opisów technicznych, umożliwiając szybkie budowanie map powiązań.

# | Cel i Zakres Projektu

- **Opracowanie Systemu:** Stworzenie prototypu konwertującego opisy tekstowe na ustrukturyzowany format grafowy.
- **Ekstrakcja Wiedzy:** Ocena zdolności modeli do identyfikacji obiektów technicznych (mosty, skrzyżowania).
- **Integracja z Neo4j:** Implementacja bazy danych umożliwiającej zaawansowaną analizę topologiczną.
- **Ewaluacja:** Testowanie dokładności na rzeczywistych danych z komunikatów GDDKiA.



# | Model Danych: Węzły i Atrybuty

| Typ Węzła (Obiektu) | Kluczowe Atrybuty (Właściwości)                          |
|---------------------|----------------------------------------------------------|
| Odcinek drogi       | nawierzchnia, długość, liczba pasów, klasa drogi         |
| Skrzyżowanie        | rodzaj (bezkolizyjne/T-kształtne), sygnalizacja świetlna |
| Rondo               | liczba wlotów, nazwa własna, lokalizacja                 |
| Obiekt inżynieryjny | typ (Most/Wiadukt/Tunel), nośność, opis techniczny       |
| Punkt POI           | kategoria (MOP, Stacja, Parking), marka/nazwa            |

# | Model Danych: Relacje Semantyczne



## ŁĄCZY\_SIĘ\_Z

Podstawowa relacja budująca topologię sieci drogi między węzłami i rondami.



## ZAWIERA

Relacja hierarchiczna: odcinek drogi zawierający obiekty inżynieryjne lub ronda.



## PRZECHODZI\_NAD/POD

Kluczowe dla analizy wielopoziomowych węzłów i obiektów nad przeszkodami.



## DOJAZD\_DO

Łączy odcinek trasy z punktami usługowymi (POI) dla użytkowników.

---

# Sekcja 2: Architektura i Metodologia

Od surowego tekstu do ustrukturyzowanej bazy  
wiedzy

# Architektura Systemu (Data Pipeline)



## Źródło Danych

Wprowadzenie  
nieustrukturyzowanych  
komunikatów technicznych  
GDDKiA w formacie  
tekstowym.



## Inferencja LLM

Analiza semantyczna tekstu  
przez model językowy w celu  
ekstrakcji encji i relacji.



## Strukturyzacja

Formatowanie wyników do  
ustrukturyzowanego formatu  
JSON zgodnie z definicją  
ontologii.



## Import Neo4j

Automatyczna transformacja  
JSON do zapytań Cypher i  
zasilenie grafowej bazy  
danych.



# ARCHITEKTURA: ORKIESTRACJA PROJEKTU

```
# Inicjalizacja nowego klienta Gemini
client = genai.Client(api_key=GEMINI_API_KEY)

driver = GraphDatabase.driver(NEO4J_URI, auth=(NEO4J_USER, NEO4J_PASSWORD))
with driver.session() as session:
```

## Integracja Hybrydowa

Kod integruje trzy kluczowe filary projektu:

-  **Google GenAI:** Wykorzystanie modelu Gemini 2.5 Flash do wnioskowania semantycznego.
-  **Neo4j Driver:** Bezpośrednia komunikacja z grafową bazą danych w chmurze (Aura).
-  **JSON:** Wykorzystany jako ustrukturyzowany format wymiany informacji (interfejs).

# LOGIKA EKSTRAKCJI: GEMINI CONFIG

```
config = types.GenerateContentConfig(  
    temperature=0.0,  
    response_mime_type="application/json"  
)
```

## Kluczowe Parametry

-  **Temperature=0.0:** Krytyczne ustawienie eliminujące losowość. Gwarantuje identyczność grafu przy powtórzeniu zapytania.
-  **MIME Type:** Wymuszenie na modelu generowania czystego kodu JSON bez zbędnych komentarzy tekstowych.
-  **System Prompt:** Wstrzyknięcie ontologii (zasad) i przykładów Few-Shot przed właściwym tekstem.

# ZASILANIE BAZY: CYPHER INTEGRATION

```
# --- FAZA I: IMPORT WĘZŁÓW ---
for node in data.get('nodes', []):
    query = f"MERGE (n:`{node['type']}` {{id: ${id}}} SET n += $props"
    session.run(query, id=node['id'], props=node['properties'])

# ZAPIS DO BAZY (Dla każdego przypadku - i poprawnego, i błędnego)
query = f"MATCH (a {{id: $source}}), (b {{id: $target}}) MERGE (a)-[:{rel_type}]->(b"
session.run(query, source=source_id, target=target_id)
```

## Transformacja JSON → Graf

Proces ładowania danych wykorzystuje mechanizmu:

-  **MERGE:** Zapobiega powstawaniu duplikatów. Jeśli węzeł o danym ID już istnieje, Cypher tylko go aktualizuje.
-  **Dynamiczne Etykiety:** Typy zdefiniowane przez AI (Odcinek, Most) stają się natywnymi etykietami w Neo4j.
-  **Rezolucja Relacji:** Matchowanie węzłów po ID przed utworzeniem połączenia.

# Soft Validation: Balans rygoru i AI

---

## **Audyt Asynchroniczny**

Zamiast sztywnego blokowania nietypowych powiązań, system stosuje miękką walidację (soft-check). Każda relacja jest porównywana z ontologią, ale jej zapis nie jest przerywany w przypadku anomalii.

## **Knowledge Enrichment**

LLM często odkrywa relacje semantyczne (np. miasto jako kontener drogi), których nie przewidziano w schemacie. Metoda ta pozwala na wzbogacenie grafu, oznaczając jednocześnie takie wpisy w logach jako "Ostrzeżenie".

# Mechanizm Obsługi Anomalii

## Pętla Walidacji Schematu

-  **Analiza Typów:** Pobranie mapy etykiet dla wszystkich węzłów.
-  **Logowanie Błędów:** Identyfikacja nieznanych relacji lub błędnych par typów.
-  **Wymuszony Zapis:** Gwarancja ciągłości procesu importu niezależnie od wyniku audytu.

WALIDACJA OSTRZEGAWCZA:  
Niedozwolone połączenie: (Miasto) -[ŁĄCZY\_SIEŻ\_Z]-> (Odcinek)

```
def save_to_neo4j(data): 1 usage
    print("Rozpaczynam miękka walidację schematu i przesyłanie do Neo4j...")

    node_type_map = {node['id']: node['type'] for node in data.get('nodes', [])}

    VALID_ONTOLOGY = {
        "ŁĄCZY_SIEŻ_Z": {
            ("Odcinek drogi", "Skrzyżowanie"), ("Skrzyżowanie", "Odcinek drogi"),
            ("Odcinek drogi", "Rondo"), ("Rondo", "Odcinek drogi")
        },
        "ZAWIERA": {
            ("Odcinek drogi", "Obiekt inżynieryjny"),
            ("Odcinek drogi", "Rondo")
        },
        "PRZECHODZI_NAD": {
            ("Obiekt inżynieryjny", "Odcinek drogi"),
            ("Odcinek drogi", "Obiekt inżynieryjny")
        },
        "PRZECHODZI_POD": {
            ("Obiekt inżynieryjny", "Odcinek drogi"),
            ("Odcinek drogi", "Obiekt inżynieryjny")
        },
        "DOJAZD_DO": {
            ("Odcinek drogi", "Punkt POI"),
            ("Obiekt inżynieryjny", "Punkt POI")
        }
    }
```

# Strategia Prompt Engineeringu

---

## Instrukcje Systemowe

Definicja roli eksperta inżynierii drogowej. Narzucenie rygorystycznych zasad ekstrakcji: dopuszczalne typy węzłów, relacji oraz wymagany format wyjściowy (Strict JSON).

## Metoda Few-Shot

Zastosowanie wzorcowych przykładów (wejście-wyjście) wewnątrz promptu. Uczy to model rozpoznawania niuansów językowych charakterystycznych dla opisów infrastruktury liniowej.

# Prompt Systemowy: Serce Ekstrakcji

## Inżynieria Instrukcji

-  **Nadanie Roli:** Definicja LLM jako "Eksperta inżynierii drogowej" wymusza użycie technicznej terminologii.
-  **Rygor Formatu:** Jawne wskazanie formatu JSON jako jedynej akceptowalnej odpowiedzi (Strict Output).
-  **Logika ID:** Wymuszenie unikalnych identyfikatorów (N1, N2...) niezbędnych do mapowania relacji.

```
SYSTEM_PROMPT = """
```

```
Jesteś ekspertem w dziedzinie inżynierii drogowej... Twoim  
zadaniem jest przekształcanie tekstowych opisów na  
ustrukturyzowany format JSON ...
```

1. DOPUSZCZALNE WĘZŁY ...
2. DOPUSZCZALNE RELACJE ...
3. ZASADY EKSTRAKCJI ...

# | Definicja Świata: Ontologia i Przykłady



## Zasady Mapowania

Prompt definiuje 5 typów węzłów (Odcinek, Skrzyżowanie, Rondo, Obiekt, POI) oraz ich obowiązkowe atrybuty.



## Gramatyka Relacji

Ograniczenie modelu do 4 relacji (ŁĄCZY\_SIĘ\_Z, ZAWIERA, PRZECHODZI\_NAD/POD, DOJAZD\_DO) budujących topologię.



## Few-Shot Learning

Dołączenie wzorcowego grafu DK13 (Przecław) jako punktu odniesienia dla "rozumienia" przez model kontekstu inżynierskiego.

**Wniosek:** Połączenie rygorystycznej ontologii z przykładem Few-Shot pozwoliło na osiągnięcie 100% pełności (Recall) w ekstrakcji strategicznych obiektów inżynierskich.



# Mechanizmy LLM: Temperatura i Tokenizacja

## Temperatura (T)

Parametr kontrolujący losowość przewidywania kolejnych słów (tokenów). W projekcie kluczowy dla stabilności struktury JSON.

- ❄️ **T = 0.0 (Determinizm):** Model zawsze wybiera najbardziej prawdopodobny token (Greedy Decoding). Niezbędne do ekstrakcji faktów technicznych.
- 🔥 **T > 0.0 (Stochastyczność):** Zwiększa "kreatywność", ale wprowadza błędy składniowe i niespójność danych.

## Tokenizacja

Proces dzielenia tekstu wejściowego na mniejsze jednostki (tokeny) zrozumiałe dla procesora GPU.

- ✂️ **Budowa mostu:** Tokeny to nie tylko całe słowa, ale też ich fragmenty lub znaki specjalne.
- ⚠️ **Zjawisko szumu:** Błędy takie jak **literówki** wynikają z nieprawidłowego przewidzenia rzadkiego ciągu tokenów w trybie stochastycznym.

# Metodologia: Wpływ Temperatury

---

- ✓ **Reżim Deterministyczny ( $T=0.0$ ):** Wykorzystany w celu zapewnienia powtarzalności wyników i stabilności składniowej plików JSON.
- ✗ **Tryb Stochastyczny ( $T>0.0$ ):** Badany pod kątem "kreatywności" modelu. Wykazano ryzyko błędów składniowych i szumu tokenizacji.
- 🧪 **Podejście Eksperymentalne:** Porównanie wielu identycznych prób dla każdego reżimu w celu weryfikacji fluktuacji determinizmu.

# Stos Technologiczny i Narzędzia

| Warstwa          | Narzędzie / Technologia | Funkcja w projekcie                          |
|------------------|-------------------------|----------------------------------------------|
| Logika Biznesowa | Python 3.10+            | Integracja komponentów i orkiestracja danych |
| Silnik AI        | LLM (Gemini 2.5 FLash)  | Przetwarzanie języka i ekstrakcja wiedzy     |
| Baza Danych      | Neo4j                   | Przechowywanie i wizualizacja grafów         |
| Język Zapytań    | Cypher                  | Manipulacja danymi wewnątrz grafu            |

---

# Sekcja 3: Dane i Eksperymenty

Analiza rzeczywistych przypadków testowych na podstawie komunikatów  
GDDKiA

# Charakterystyka Danych Testowych

---

Eksperymenty przeprowadzono na oficjalnych komunikatach Generalnej Dyrekcji Dróg Krajowych i Autostrad (GDDKiA), reprezentujących różne stopnie skomplikowania infrastruktury:

## 1. Rozbudowa Autostrady A4

Teksty opisujące plany rozbudowy o dodatkowe pasy ruchu, przebudowę węzłów oraz budowę nowych Miejsc Obsługi Podróżnych (MOP).

## 2. Modernizacja DK7 (Węzeł Krzyszkowice)

Dokumentacja dotycząca likwidacji niebezpiecznego skrzyżowania kolizyjnego i budowy bezkolizyjnego węzła z tunelem i wiaduktem.

## 1. Rozbudowa Autostrady A4 + Modernizacja DK7 (Węzeł Krzyszkowice) – fuzja


Tekst łączące obydwa teksty. Sprawdza czy model poprawnie połączy je i znajdzie element wspólny sieci (Kraków).

# Case Study: Modernizacja Zakopianki (DK7)


Analiza tekstu technicznego dotyczącego przebudowy układu komunikacyjnego w Krzyszkowicach. Kluczowym wyzwaniem była ekstrakcja relacji między trasą główną (tranzytową) a nowymi drogami lokalnymi.

## Specyfika Danych:

- ✓ **Obiekty:** Tunel pod DK7, mosty na potokach Krzyszkowianka i Młynówka.
- ✓ **Relacje:** Likwidacja lewoskrętów na rzecz bezkolizyjnego węzła.
- ✓ **Punkty POI:** Przysiółki (Bugaj, Psiary) jako punkty docelowe dróg lokalnych.



# Wizualizacja Wyników w Neo4j



## Struktura wygenerowanego grafu

Na powyższym schemacie widoczna jest bezpośrednia implementacja wyekstrahowanych danych w bazie Neo4j:

- Węzły centralne:** Reprezentują kluczowe odcinki dróg (np. A4, DK7).
- Obiekty inżynieryjne:** Obiekty inżynieryjne (Wiadukty, Tunele) osadzone na trasie poprzez relację ZAWIERA.
- Skrzyżowania**
- POI**

→ **Topologia:** Strzałki relacji precyzyjnie odwzorowują kierunki potoków ruchu opisane w komunikatach prasowych.

# Ekstrakcja Wiedzy: Ziarno vs Próba nr 1


| Metryka / Element    | Wzorzec (Ziarno)  | Wynik LLM (Próba nr 1) | Wniosek                                                                              |
|----------------------|-------------------|------------------------|--------------------------------------------------------------------------------------|
| Liczba Węzłów        | 18 węzłów         | 24 węzły               | Nad-ekstrakcja: model wyodrębnił dodatkowe skrzyżowania (Mogilany, Głogoczów).       |
| Klasyfikacja Dróg    | "GP" dla DK7      | "DK" oraz "lokalna"    | Model wprowadził semantyczny podział klas dróg, którego nie było w ziarnie.          |
| Typy Relacji         | ŁĄCZY_SIE_Z       | DOJAZD_DO              | Różnica logiczna: LLM zinterpretował połączenie drogi z węzłem jako funkcję dojazdu. |
| Relacje Przestrzenne | ZAWIERA (Obiekty) | PRZECHODZI_NAD         | <b>Sukces:</b> Model poprawnie zidentyfikował bezkolizyjność kładek dla pieszych.    |

**Obserwacja kluczowa:** Próba nr 1 wykazuje tendencję do "wzbogacania" grafu o dodatkowe punkty węzłowe wspomniane w tekście pobocznie (tzw. węzły satelickie), co zwiększa ziarnistość danych kosztem precyzji względem surowego wzorca.



# Case Study 2: Rozbudowa Autostrady A4

Analiza objęła blisko 120-kilometrowy odcinek autostrady A4 w województwach śląskim i małopolskim. Był to najbardziej wymagający tekst pod kątem gęstości informacji technicznych.



# Case Study: Rozbudowa Autostrady A4


## Złożoność Ekstrakcji Wiedzy

Eksperyment na danych A4 wykazał najwyższą "inteligencję topologiczną" modelu LLM. System nie tylko przeniósł dane, ale zaproponował własną strukturę logiczną.

 **Odkrycie Hierarchii:** Model zidentyfikował węzeł nadrzędny "Autostrada A4" (669 km), spinający wszystkie pod-odcinki.

 **Kontekst Miejski:** Samodzielna ekstrakcja miast (Katowice, Kraków) jako punktów docelowych/węzłowych.

 **Relacje Inkluzji:** Poprawne zastosowanie relacji ZAWIERA dla MOP-ów i mostów.



# Analiza Porównawcza: Ziarno vs Próba (A4)

| Cecha Strukturalna   | Wzorzec (Ziarno)        | Wynik LLM (Próba nr 1)                                          | Komentarz Badawczy                                                      |
|----------------------|-------------------------|-----------------------------------------------------------------|-------------------------------------------------------------------------|
| Liczba Węzłów        | 22 węzły                | 27 węzłów                                                       | Zwiększona ziarnistość przez dodanie miast i węzła głównego.            |
| Topologia            | Płaska (lista odcinków) | Hierarchiczna (Rodzic-Dziecko)                                  | Model LLM poprawnie zdefiniował A4 jako "kontener" dla mniejszych dróg. |
| Kompletność (Recall) | 100%                    | Zero pominięć (False Negatives) w kluczowych mostach i MOP-ach. |                                                                         |
| Relacje POI          | DOJAZD_DO               | ZAWIERA / DOJAZD_DO                                             | Model użył relacji zawierania dla MOP-ów, co jest technicznie zasadne.  |

💡**Wniosek:** Różnica między Ziarnem a Próbą wynika z **pozytywnej nad-ekstrakcji**. Model LLM "rozumie" infrastrukturę lepiej niż surowy algorytm, uzupełniając brakujące powiązania logiczne między regionami a drogą.

# Zdolność LLM do Hierarchizacji Wiedzy

## Struktura Makro- i Mikrogeograficzna

Model wykazał się "inteligencją topologiczną", automatycznie porządkując dane w hierarchię:

- **Węzeł Nadrzędny:** Utworzenie obiektu "Autostrada A4" (669 km).
- **Pod-odcinki:** Przypisanie konkretnych fragmentów (np. Buczyna-Balice) jako części składowe.
- **Infrastruktura:** Osadzenie 42 mostów i wiaduktów wewnątrz właściwych odcinków (relacja ZAWIERA).

## Interpretacja Granic Grafu

Model prawidłowo zinterpretował przyimki "od... do...", co jest kluczowe dla ramowania sieci:

- 📍 **Węzły Terminalowe:** Rozpoznanie punktów stykowych (np. Węzeł Balice) jako granic odcinka.
- 🔗 **Relacje Stykowe:** Zastosowanie relacji ŁĄCZY\_SIE\_Z zamiast ZAWIERA dla punktów końcowych, co pozwala na modułarną rozbudowę grafu o kolejne drogi.


# Fuzja Wiedzy: Eksperyment Zintegrowany (A4 + DK7)

## Koncepcja „Super-Ziarna”

Przetworzenie połączonych komunikatów technicznych w ramach jednego okna kontekstowego (Single-Context Window) w celu uzyskania spójnej sieci regionalnej.

 **Rezolucja Identyfikatorów:** Przesunięcie sekwencyjne ID (A4: N1-N22, Zakopianka: N24-N41) w celu uniknięcia kolizji w bazie danych.

 **Podejście Single-Context:** Pozwala modelowi LLM na jednoczesny dostęp do obu tekstów, co jest kluczem do odnalezienia punktów wspólnych.



# Stabilność Fuzji i Fluktuacje Determinizmu

## Analiza powtarzalności dla danych wieloźródłowych

Mimo ustawienia temperatury  $T=0.0$ , wysoka gęstość informacji w połączonym tekście ujawniła zjawisko fluktuacji probabilistycznej:

### ✓ Próba 1 i 3 (Sukces Dominujący)

Pełna fuzja topologiczna. Model poprawnie zunifikował węzeł krakowski i utrzymał spójność sieci. **F1-Score: 87.2%**.

### ! Próba 2 (Anomalia Strukturalna)

Model zrezygnował z agregacji wokół wspólnego węzła na rzecz zapisu cech geograficznych wewnątrz atrybutów. **F1-Score: 85.4%**.

# Próba nr 1: Sukces Rezolucji Encji i Fuzji – Kraków jako „Anchor Node”


## Prawidłowa Abstrakcja Geograficzna

Model w tej próbie zachował się jak rasowy inżynier GIS – dostrzegł, że "Kraków" to punkt centralny dla obu systemów drogowych.

- 🔗 **Utworzenie Węzła Centralnego:** Model wyodrębnił węzeł N26 (Miasto: Kraków).
- 🔗 **Kotwiczenie Autostrady A4:** Odcinek Katowice–Kraków (N24) został połączony bezpośrednią relacją ŁĄCZY\_SIĘ\_Z z Krakowem (N26).
- 🔗 **Kotwiczenie Zakopianki:** Odcinek DK7 Kraków–Myślenice (N40) również został połączony relacją ŁĄCZY\_SIĘ\_Z z tym samym Krakowem (N26).

## Efekt w bazie Neo4j:

Dzięki spięciu obu dróg przez wspólny punkt referencyjny (Węzeł N26), algorytmy przeszukiwania grafu (np. Dijkstra/A\*) mogą bez przeszkód wyznaczać trasy tranzytowe z Katowic prosto w Tatry. Fuzja zakończyła się pełnym sukcesem topologicznym.



# Próba nr 2: Awaria Fuzji ("Wyspy Danych")


## Błąd Semantycznego Rozproszenia

W tej próbie model stracił zdolność abstrakcji encji nadrzędnych. Zamiast stworzyć jeden węzeł dla miasta Kraków, zamknął informację geograficzną wewnątrz stringów.

- ❌ **Brak Węzła Wspólnego:** W spisie 55 węzłów nie istnieje dedykowany obiekt dla Krakowa ani Balic (Balice pojawiają się tylko jako Punkt POI N28, ale nie są połączone z DK7).
- ⚠️ **Informacja jako Tekst, nie Obiekt:** Słowo "Kraków" zostało uwięzione w nazwach odcinków: N25 ("A4 Katowice – Kraków"), N27 ("A4 Katowice – Balice"), N32 ("Zakopianka Kraków – Myślenice").

## Skutek dla bazy danych:

Analiza relacji w Próbie nr 2 wykazuje **\*\*całkowity brak połączenia\*\*** pomiędzy podsiecią A4 a podsiecią DK7. Powstały dwie całkowicie odizolowane "wyspy danych". System komputerowy analizujący ten graf uznałby, że z autostrady A4 nie da się zjechać na Zakopiankę, co eliminuje ten graf z użytku inżynierskiego.






# Fuzja Wiedzy i Entity Resolution

## Integracja Wieloźródłowa

Największym sukcesem projektu była zdolność modelu do autonomicznego łączenia grafów z różnych dokumentów (A4 oraz DK7).

-  **Węzeł Kotwiczący:** Automatyczne rozpoznanie "Krakowa" jako wspólnego punktu referencyjnego.
-  **Scalenie Topologii:** Połączenie końca Autostrady A4 z początkiem Zakopianki w jedną sieć.
-  **Rezultat:** Przejście z odizolowanych "wysp danych" do zintegrowanego grafu transportowego regionu.



# Ewaluacja Fuzji Wiedzy: Ziarno vs Próba 1 i 2

| Cecha Strukturalna           | Wzorzec (Ziarno Małopolski)              | Próba nr 1 (Sukces Fuzji)                   | Próba nr 2 (Anomalia Strukturalna)                             |
|------------------------------|------------------------------------------|---------------------------------------------|----------------------------------------------------------------|
| Liczba Węzłów                | 41 węzłów                                | 53 węzły (Nad-ekstrakcja kontekstowa)       | 55 węzłów (Nadmierna segmentacja)                              |
| Encja Kotwicząca<br>(Kraków) | Wyodrębniona jako osobny węzeł POI (N23) | Wyodrębniona jako osobny węzeł Miasto (N26) | <b>Brak węzła.</b> Rozproszona w nazwach właściwości odcinków. |
| Topologia Sieci              | Zintegrowany graf (Jedna sieć)           | Połączona spójnie                           | Rozbita (2 odizolowane subgrafy)                               |
| Relacje Nadrzędne            | Płaskie mapowanie ciągów                 | A4 zdefiniowana jako kontener makro (N1)    | A4 zdefiniowana jako kontener makro (N1)                       |

Wniosek metodologiczny: Mimo identycznego promptu i reżimu temperaturowego (T=0.0), wysokie zagęszczenie informacji w tekście zintegrowanym wywołało fluktuację probabilistyczną, prowadząc do dwóch skrajnie różnych strategii mapowania świata przez LLM.



# Sekcja 4: Ewaluacja i Wyniki Badawcze

Analiza skuteczności, anomalie generatywne oraz fuzja danych

# Determinizm vs Stochastyczność

---

## Reżim Deterministyczny ( $T=0.0$ )

Ustawienie temperatury na poziomie 0.0 (Greedy Decoding) gwarantuje **100% powtarzalności struktury** przy wielokrotnych próbach.

- ✓ Stabilność składniowa JSON.
- ✓ Przewidywalność schematu danych.
- ✓ Idealne do zasilania baz produkcyjnych.

## Reżim Stochastyczny ( $T>0.0$ )

Podniesienie temperatury stymuluje model do nieliniowej analizy, ale wprowadza **fluktuacje probabilistyczne** i błędy.

- ⚠ Ryzyko błędów ortograficznych w kluczach.
- ⚠ Niespójność identyfikatorów węzłów.
- 💡 Wyższy poziom abstrakcji (hierarchizacja).

# Analiza Anomalii: Tokenization Noise

---

## Zjawisko błędu syntaktycznego

Eksperymenty w trybie stochastycznym ujawniły błędy tokenizacji, które uniemożliwiają automatyczny import do bazy Neo4j.

```
"source": "N3",  
"target": "N9",  
"type": "ŁĄCZY SIĘ Z"
```

*Błąd: Nadmiarowy token "ł" w nazwie relacji.*

**Rozwiązanie:** Wdrożenie warstwy walidacji **Pydantic** wymuszającej zgodność ze schematem przed importem.

# Ewaluacja Jakościowa: Recall i Precision

## Recall (Pełność / Czułość)

Odpowiada na pytanie: *"Jaki procent rzeczywistych obiektów z tekstu udało się modelowi odnaleźć?"*

**Wzór matematyczny:**

$$\text{Recall} = \frac{TP}{TP + FN}$$

*W naszym projekcie Recall = 100%, co oznacza całkowity brak pominąć obiektów krytycznych (mosty, wiadukty).*

## Precision (Precyzja)

Odpowiada na pytanie: *"Ile z obiektów wygenerowanych przez model faktycznie powinno znaleźć się w grafie?"*

**Wzór matematyczny:**

$$\text{Precision} = \frac{TP}{TP + FP}$$

*Niższa precyzja (~77%) wynika z dodawania przez LLM węzłów kontekstowych (miasta, regiony), których nie było we wzorcowym ziarnie.*

# Ewaluacja Całościowa: F1-Score i Jaccard

## F1-Score

Średnia harmoniczna precyzji i pełności. Jest to najbardziej obiektywna miara skuteczności modelu.

$$F_1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

Wynik **87.2%** potwierdza bardzo wysoką sprawność modelu w zadaniach inżynierii danych.

## Indeks Jaccarda (Similarity)

Mierzy podobieństwo dwóch zbiorów (Wzorzec vs Wynik AI). Oblicza stosunek części wspólnej do sumy zbiorów.

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

Wartość **0.77** wskazuje na silną zbieżność topologiczną wygenerowanego grafu z rzeczywistym układem drogowym.

# Metryki Jakościowe i Ilościowe (połączone teskty –udane próby)

100%

Recall (Pełność)

~77%

Precision (Precyzja)

87.24%

F1-Score

77.36%

Indeks Jaccarda

**Interpretacja wyników:** Stuprocentowa pełność (Recall) gwarantuje, że model nie pomija kluczowych danych technicznych. Niższa precyzja wynika z "nad-ekstrakcji" (tworzenia dodatkowych węzłów kontekstowych dla miast i regionów), co w kontekście budowania bazy wiedzy jest traktowane jako cecha pozytywna (Knowledge Enrichment).





# **Sekcja 5: Podsumowanie, Wyniki i Rekomendacje**

Kompleksowy bilans projektu, analiza mocnych i słabych stron oraz wnioski  
wdrożeńowe

# Plusy (Silne Strony) Zaproponowanej Metody

---

## Efektywność i Skalowalność

-  **Radykalna automatyzacja:** Skrócenie czasu ekstrakcji danych z dokumentacji technicznej z godzin (praca manualna) do sekund.
-  **Przetwarzanie masowe:** Możliwość równoległej analizy setek komunikatów i raportów bez wzrostu zapotrzebowania na zasoby ludzkie.

## Głęboka Semantyczna i Fuzja

-  **Recall na poziomie 100%:** Gwarancja, że żaden kluczowy obiekt infrastruktury wymieniony w tekście nie zostanie pominięty.
-  **Autonomiczne Entity Resolution:** Zdolność do samodzielnego łączenia niezależnych dokumentów w jedną logiczną sieć grafową (np. wokół węzłów miejskich).

# Minusy (Ograniczenia i Słabe Strony)

---

## Problemy Generatywne i Składniowe

-  **Szum Tokenizacji ( $T > 0.0$ ):** Ryzyko powstawania błędów w nazwach relacji (np. "ŁĄCZY\_SIIĘ\_Z"), blokujących import do bazy.
-  **Nad-ekstrakcja (False Positives):** Tworzenie nadmiarowych, ogólnych węzłów kontekstowych (np. regionów), co obniża precyzję.

## Zależności Technologiczne

-  **Wrażliwość na Prompting:** Wynik końcowy jest silnie uzależniony od precyzyjnej konstrukcji instrukcji systemowych i przykładów Few-Shot.
-  **Koszty utrzymania:** Komercyjne API (OpenAI/Gemini) generują koszty proporcjonalne do wolumenu tokenów przy skomplikowanych promptach.

# Kluczowe Wnioski Badawcze i Metodologiczne

---

-  **Prymat Pełnego Determinizmu ( $T=0.0$ ):** Dla systemów zasilających relacyjne lub grafowe bazy danych, temperatura zero jest warunkiem koniecznym do zachowania spójności schematu.
-  **Niezbędność Walidacji Hybrydowej:** Sam model LLM nie jest systemem autonomicznym. Konieczne jest stosowanie zewnętrznych parserów (np. Pydantic, JSON Schema) jako "bezpieczników" strukturalnych.
-  **Graf jako Optymalny Model Świata:** Baza Neo4j idealnie odzwierciedla nieliniową i wielopoziomową naturę opisów infrastruktury liniowej, przewyższając klasyczne tabele relacyjne.

# Rekomendacje dla Wdrożeń Przemysłowych

---

## Architektura Systemu

**Podejście Human-in-the-Loop:** System powinien generować graf jako "wersję kandydacką" (wstępną), która podlega szybkiej, wizualnej akceptacji przez inżyniera kontraktu, eliminując błędy typu False Positive.

## Optymalizacja i Bezpieczeństwo

**Lokalne Modele LLM (Open-Source):** W celu redukcji kosztów API oraz ochrony danych wrażliwych (np. niepubliczne plany przetargowe), rekomenduje się migrację na wyspecjalizowane, lokalne modele klasy Llama-3 lub Mistral dostrojone do języka polskiego.

# Dziękujemy za uwagę

**Automatyczne generowanie grafów infrastruktury liniowej z użyciem LLM**

Prezentacja końcowa projektu badawczego | 2026

Mateusz Młynek, Michał Szczepanik

---