

Wykorzystanie LLM do Automatycznej Analizy Infrastruktury drogowej

Generowanie i analiza grafów sieci liniowych z użyciem dużych modeli językowych i baz grafowych Neo4j

Sekcja 1: Wprowadzenie i Kontekst

Definicja problemu, cele oraz fundamenty modelu danych

| Kontekst i Wyzwania Badawcze

Tradycyjne Metody

Modelowanie infrastruktury (sieci drogowe, wodociągowe) opiera się obecnie na manualnej digitalizacji. Jest to proces czasochłonny, kosztowny i obarczony wysokim ryzykiem błędów ludzkich.

Potencjał Technologii

Duże Modele Językowe (LLM) oferują nowe możliwości w automatycznej ekstrakcji informacji z nieustrukturyzowanych opisów technicznych, umożliwiając szybkie budowanie map powiązań.

| Cel i Zakres Projektu

- **Opracowanie Systemu:** Stworzenie prototypu konwertującego opisy tekstowe na ustrukturyzowany format grafowy.
- **Ekstrakcja Wiedzy:** Ocena zdolności modeli do identyfikacji obiektów technicznych (mosty, skrzyżowania).
- **Integracja z Neo4j:** Implementacja bazy danych umożliwiającej zaawansowaną analizę topologiczną.
- **Ewaluacja:** Testowanie dokładności na rzeczywistych danych z komunikatów GDDKiA.



| Model Danych: Węzły i Atrybuty

Typ Węzła (Obiektu)	Kluczowe Atrybuty (Właściwości)
Odcinek drogi	nawierzchnia, długość, liczba pasów, klasa drogi
Skrzyżowanie	rodzaj (bezkolizyjne/T-kształtne), sygnalizacja świetlna
Rondo	liczba wlotów, nazwa własna, lokalizacja
Obiekt inżynieryjny	typ (Most/Wiadukt/Tunel), nośność, opis techniczny
Punkt POI	kategoria (MOP, Stacja, Parking), marka/nazwa

| Model Danych: Relacje Semantyczne



ŁĄCZY_SIĘ_Z

Podstawowa relacja budująca topologię sieci drogi między węzłami i rondami.



ZAWIERA

Relacja hierarchiczna: odcinek drogi zawierający obiekty inżynieryjne lub ronda.



PRZECHODZI_NAD/POD

Kluczowe dla analizy wielopoziomowych węzłów i obiektów nad przeszkodami.



DOJAZD_DO

Łączy odcinek trasy z punktami usługowymi (POI) dla użytkowników.

Sekcja 2: Architektura i Metodologia

Od surowego tekstu do ustrukturyzowanej bazy
wiedzy

Architektura Systemu (Data Pipeline)



Źródło Danych

Wprowadzenie
nieustrukturyzowanych
komunikatów technicznych
GDDKiA w formacie
tekstowym.



Inferencja LLM

Analiza semantyczna tekstu
przez model językowy w celu
ekstrakcji encji i relacji.



Strukturyzacja

Formatowanie wyników do
ustrukturyzowanego formatu
JSON zgodnie z definicją
ontologii.



Import Neo4j

Automatyczna transformacja
JSON do zapytań Cypher i
zasilenie grafowej bazy
danych.

ARCHITEKTURA: ORKIESTRACJA PROJEKTU

```
import json from google import genai from neo4j import GraphDatabase
# Inicjalizacja połączeń client =
genai.Client(api_key=GEMINI_API_KEY) driver =
GraphDatabase.driver(NEO4J_URI, auth=(USER, PWD))
```

Integracja Hybrydowa

Kod integruje trzy kluczowe filary projektu:

-  **Google GenAI:** Wykorzystanie modelu Gemini 1.5 Flash do wnioskowania semantycznego.
-  **Neo4j Driver:** Bezpośrednia komunikacja z grafową bazą danych w chmurze (Aura).
-  **JSON:** Wykorzystany jako ustrukturyzowany format wymiany informacji (interfejs).

LOGIKA EKSTRAKCJI: GEMINI CONFIG

```
config = types.GenerateContentConfig( temperatur =0. ,  
response_mime_type="application/json" ) response =  
client.models.generate_content( model="gemini-1.5-flash",  
contents=f"{SYSTEM_PROMPT}\n{raw_text}", config=config )
```

Kluczowe Parametry

-  **Temperature=0.0:** Krytyczne ustawienie eliminujące losowość. Gwarantuje identyczność grafu przy powtórzeniu zapytania.
-  **MIME Type:** Wymuszenie na modelu generowania czystego kodu JSON bez zbędnych komentarzy tekstowych.
-  **System Prompt:** Wstrzyknięcie ontologii (zasad) i przykładów Few-Shot przed właściwym tekstem.

ZASILANIE BAZY: CYPHER INTEGRATION

```
for node in data['nodes']: query = "MERGE (n:`{node['type']}` {id: $id}) SET n += $props" session.run(query, id=node['id'], props=node['properties']) for rel in data['relationships']: query = "MATCH (a {id: $source}), (b {id: $target}) MERGE (a)-[:{rel['type']}]>(b)" session.run(query, source=rel['source'], target=rel['target'])
```

Transformacja JSON → Graf

Proces ładowania danych wykorzystuje mechanizmu:

-  **MERGE:** Zapobiega powstawaniu duplikatów. Jeśli węzeł o danym ID już istnieje, Cypher tylko go aktualizuje.
-  **Dynamiczne Etykiety:** Typy zdefiniowane przez AI (Odcinek, Most) stają się natywnymi etykietami w Neo4j.
-  **Rezolucja Relacji:** Matchowanie węzłów po ID przed utworzeniem połączenia.

Strategia Prompt Engineeringu

Instrukcje Systemowe

Definicja roli eksperta inżynierii drogowej. Narzucenie rygorystycznych zasad ekstrakcji: dopuszczalne typy węzłów, relacji oraz wymagany format wyjściowy (Strict JSON).

Metoda Few-Shot

Zastosowanie wzorcowych przykładów (wejście-wyście) wewnątrz promptu. Uczy to model rozpoznawania niuansów językowych charakterystycznych dla opisów infrastruktury liniowej.

Prompt Systemowy: Serce Ekstrakcji

Inżynieria Instrukcji

-  **Nadanie Roli:** Definicja LLM jako "Eksperta inżynierii drogowej" wymusza użycie technicznej terminologii.
-  **Rygor Formatu:** Jawne wskazanie formatu JSON jako jedynej akceptowalnej odpowiedzi (Strict Output).
-  **Logika ID:** Wymuszenie unikalnych identyfikatorów (N1, N2...) niezbędnych do mapowania relacji.

```
SYSTEM_PROMPT = """
```

```
Jesteś ekspertem w dziedzinie inżynierii drogowej... Twoim  
zadaniem jest przekształcanie tekstowych opisów na  
ustrukturyzowany format JSON ...
```

1. DOPUSZCZALNE WĘZŁY ...
2. DOPUSZCZALNE RELACJE ...
3. ZASADY EKSTRAKCJI ...

| Definicja Świata: Ontologia i Przykłady



Zasady Mapowania

Prompt definiuje 5 typów węzłów (Odcinek, Skrzyżowanie, Rondo, Obiekt, POI) oraz ich obowiązkowe atrybuty.



Gramatyka Relacji

Ograniczenie modelu do 4 relacji (ŁĄCZY_SIĘ_Z, ZAWIERA, PRZECHODZI_NAD/POD, DOJAZD_DO) budujących topologię.



Few-Shot Learning

Dołączenie wzorcowego grafu DK13 (Przecław) jako punktu odniesienia dla "rozumienia" przez model kontekstu inżynierskiego.

Wniosek: Połączenie rygorystycznej ontologii z przykładem Few-Shot pozwoliło na osiągnięcie 100% pełności (Recall) w ekstrakcji strategicznych obiektów inżynierskich.

Mechanizmy LLM: Temperatura i Tokenizacja

Temperatura (T)

Parametr kontrolujący losowość przewidywania kolejnych słów (tokenów). W projekcie kluczowy dla stabilności struktury JSON.

- ❄️ **T = 0.0 (Determinizm):** Model zawsze wybiera najbardziej prawdopodobny token (Greedy Decoding). Niezbędne do ekstrakcji faktów technicznych.
- 🔥 **T > 0.0 (Stochastyczność):** Zwiększa "kreatywność", ale wprowadza błędy składniowe i niespójność danych.

Tokenizacja

Proces dzielenia tekstu wejściowego na mniejsze jednostki (tokeny) zrozumiałe dla procesora GPU.

- ✂️ **Budowa mostu:** Tokeny to nie tylko całe słowa, ale też ich fragmenty lub znaki specjalne.
- ⚠️ **Zjawisko szumu:** Błędy takie jak **literówki** wynikają z nieprawidłowego przewidzenia rzadkiego ciągu tokenów w trybie stochastycznym.

Metodologia: Wpływ Temperatury

- ✓ **Reżim Deterministyczny ($T=0.0$):** Wykorzystany w celu zapewnienia powtarzalności wyników i stabilności składniowej plików JSON.
- ✗ **Tryb Stochastyczny ($T>0.0$):** Badany pod kątem "kreatywności" modelu. Wykazano ryzyko błędów składniowych i szumu tokenizacji.
- 🧪 **Podejście Eksperymentalne:** Porównanie wielu identycznych prób dla każdego reżimu w celu weryfikacji fluktuacji determinizmu.

Stos Technologiczny i Narzędzia

Warstwa	Narzędzie / Technologia	Funkcja w projekcie
Logika Biznesowa	Python 3.10+	Integracja komponentów i orkiestracja danych
Silnik AI	LLM (Gemini 2.5 FLash)	Przetwarzanie języka i ekstrakcja wiedzy
Baza Danych	Neo4j	Przechowywanie i wizualizacja grafów
Język Zapytań	Cypher	Manipulacja danymi wewnątrz grafu

Sekcja 3: Dane i Eksperymenty

Analiza rzeczywistych przypadków testowych na podstawie komunikatów
GDDKiA

Charakterystyka Danych Testowych

Eksperymenty przeprowadzono na oficjalnych komunikatach Generalnej Dyrekcji Dróg Krajowych i Autostrad (GDDKiA), reprezentujących różne stopnie skomplikowania infrastruktury:

1. Rozbudowa Autostrady A4

Teksty opisujące plany rozbudowy o dodatkowe pasy ruchu, przebudowę węzłów oraz budowę nowych Miejsc Obsługi Podróżnych (MOP).

2. Modernizacja DK7 (Węzeł Krzyszkowice)

Dokumentacja dotycząca likwidacji niebezpiecznego skrzyżowania kolizyjnego i budowy bezkolizyjnego węzła z tunelem i wiaduktem.

1. Rozbudowa Autostrady A4 + Modernizacja DK7 (Węzeł Krzyszkowice) – fuzja


Tekst łączące obydwa teksty. Sprawdza czy model poprawnie połączy je i znajdzie element wspólny sieci (Kraków).

Case Study: Modernizacja Zakopianki (DK7)


Analiza tekstu technicznego dotyczącego przebudowy układu komunikacyjnego w Krzyszkowicach. Kluczowym wyzwaniem była ekstrakcja relacji między trasą główną (tranzytową) a nowymi drogami lokalnymi.

Specyfika Danych:

- ✓ **Obiekty:** Tunel pod DK7, mosty na potokach Krzyszkowianka i Młynówka.
- ✓ **Relacje:** Likwidacja lewoskrętów na rzecz bezkolizyjnego węzła.
- ✓ **Punkty POI:** Przysiółki (Bugaj, Psiary) jako punkty docelowe dróg lokalnych.



Wizualizacja Wyników w Neo4j



Struktura wygenerowanego grafu

Na powyższym schemacie widoczna jest bezpośrednia implementacja wyekstrahowanych danych w bazie Neo4j:

- Węzły centralne:** Reprezentują kluczowe odcinki dróg (np. A4, DK7).
- Obiekty inżynieryjne:** Obiekty inżynieryjne (Wiadukty, Tunele) osadzone na trasie poprzez relację ZAWIERA.
- Skrzyżowania**
- POI**

→ **Topologia:** Strzałki relacji precyzyjnie odwzorowują kierunki potoków ruchu opisane w komunikatach prasowych.


Ekstrakcja Wiedzy: Ziarno vs Próba nr 1

Metryka / Element	Wzorzec (Ziarno)	Wynik LLM (Próba nr 1)	Wniosek
Liczba Węzłów	18 węzłów	24 węzły	Nad-ekstrakcja: model wyodrębnił dodatkowe skrzyżowania (Mogilany, Głogoczów).
Klasyfikacja Dróg	"GP" dla DK7	"DK" oraz "lokalna"	Model wprowadził semantyczny podział klas dróg, którego nie było w ziarnie.
Typy Relacji	ŁĄCZY_SIE_Z	DOJAZD_DO	Różnica logiczna: LLM zinterpretował połączenie drogi z węzłem jako funkcję dojazdu.
Relacje Przestrzenne	ZAWIERA (Obiekty)	PRZECHODZI_NAD	Sukces: Model poprawnie zidentyfikował bezkolizyjność kładek dla pieszych.

Obserwacja kluczowa: Próba nr 1 wykazuje tendencję do "wzbogacania" grafu o dodatkowe punkty węzłowe wspomniane w tekście pobocznie (tzw. węzły satelickie), co zwiększa ziarnistość danych kosztem precyzji względem surowego wzorca.

Case Study 2: Rozbudowa Autostrady A4

Analiza objęła blisko 120-kilometrowy odcinek autostrady A4 w województwach śląskim i małopolskim. Był to najbardziej wymagający tekst pod kątem gęstości informacji technicznych.



Case Study: Rozbudowa Autostrady A4


Złożoność Ekstrakcji Wiedzy

Eksperyment na danych A4 wykazał najwyższą "inteligencję topologiczną" modelu LLM. System nie tylko przeniósł dane, ale zaproponował własną strukturę logiczną.

 **Odkrycie Hierarchii:** Model zidentyfikował węzeł nadrzędny "Autostrada A4" (669 km), spinający wszystkie pod-odcinki.

 **Kontekst Miejski:** Samodzielna ekstrakcja miast (Katowice, Kraków) jako punktów docelowych/węzłowych.

 **Relacje Inkluzji:** Poprawne zastosowanie relacji ZAWIERA dla MOP-ów i mostów.



Analiza Porównawcza: Ziarno vs Próba (A4)

Cecha Strukturalna	Wzorzec (Ziarno)	Wynik LLM (Próba nr 1)	Komentarz Badawczy
Liczba Węzłów	22 węzły	27 węzłów	Zwiększona ziarnistość przez dodanie miast i węzła głównego.
Topologia	Płaska (lista odcinków)	Hierarchiczna (Rodzic-Dziecko)	Model LLM poprawnie zdefiniował A4 jako "kontener" dla mniejszych dróg.
Kompletność (Recall)	100%	Zero pominięć (False Negatives) w kluczowych mostach i MOP-ach.	
Relacje POI	DOJAZD_DO	ZAWIERA / DOJAZD_DO	Model użył relacji zawierania dla MOP-ów, co jest technicznie zasadne.

 **Wniosek:** Różnica między Ziarnem a Próbą wynika z **pozytywnej nad-ekstrakcji**. Model LLM "rozumie" infrastrukturę lepiej niż surowy algorytm, uzupełniając brakujące powiązania logiczne między regionami a drogą.

Zdolność LLM do Hierarchizacji Wiedzy

Struktura Makro- i Mikrogeograficzna

Model wykazał się "inteligencją topologiczną", automatycznie porządkując dane w hierarchię:

- **Węzeł Nadrzędny:** Utworzenie obiektu "Autostrada A4" (669 km).
- **Pod-odcinki:** Przypisanie konkretnych fragmentów (np. Buczyna-Balice) jako części składowe.
- **Infrastruktura:** Osadzenie 42 mostów i wiaduktów wewnątrz właściwych odcinków (relacja ZAWIERA).

Interpretacja Granic Grafu

Model prawidłowo zinterpretował przyimki "od... do...", co jest kluczowe dla ramowania sieci:

- 📍 **Węzły Terminalowe:** Rozpoznanie punktów stykowych (np. Węzeł Balice) jako granic odcinka.
- 🔗 **Relacje Stykowe:** Zastosowanie relacji ŁĄCZY_SIE_Z zamiast ZAWIERA dla punktów końcowych, co pozwala na modułarną rozbudowę grafu o kolejne drogi.


Fuzja Wiedzy: Eksperyment Zintegrowany (A4 + DK7)

Koncepcja „Super-Ziarna”

Przetworzenie połączonych komunikatów technicznych w ramach jednego okna kontekstowego (Single-Context Window) w celu uzyskania spójnej sieci regionalnej.

 **Rezolucja Identyfikatorów:** Przesunięcie sekwencyjne ID (A4: N1-N22, Zakopianka: N24-N41) w celu uniknięcia kolizji w bazie danych.

 **Podejście Single-Context:** Pozwala modelowi LLM na jednoczesny dostęp do obu tekstów, co jest kluczem do odnalezienia punktów wspólnych.



Stabilność Fuzji i Fluktuacje Determinizmu

Analiza powtarzalności dla danych wieloźródłowych

Mimo ustawienia temperatury $T=0.0$, wysoka gęstość informacji w połączonym tekście ujawniła zjawisko fluktuacji probabilistycznej:

✓ Próba 1 i 3 (Sukces Dominujący)

Pełna fuzja topologiczna. Model poprawnie zunifikował węzeł krakowski i utrzymał spójność sieci. **F1-Score: 87.2%**.

! Próba 2 (Anomalia Strukturalna)

Model zrezygnował z agregacji wokół wspólnego węzła na rzecz zapisu cech geograficznych wewnątrz atrybutów. **F1-Score: 85.4%**.

Wniosek: Przy złożonych integracjach, LLM wykazuje stabilność dominującą (66% sukcesu fuzji), co sugeruje potrzebę stosowania mechanizmu głosowania większościowego (Ensemble Method) w systemach produkcyjnych.

Próba nr 1: Sukces Rezolucji Encji i Fuzji – Kraków jako „Anchor Node”


Prawidłowa Abstrakcja Geograficzna

Model w tej próbie zachował się jak rasowy inżynier GIS – dostrzegł, że "Kraków" to punkt centralny dla obu systemów drogowych.

- 🔗 **Utworzenie Węzła Centralnego:** Model wyodrębnił węzeł N26 (Miasto: Kraków).
- 🔗 **Kotwiczenie Autostrady A4:** Odcinek Katowice–Kraków (N24) został połączony bezpośrednią relacją ŁĄCZY_SIĘ_Z z Krakowem (N26).
- 🔗 **Kotwiczenie Zakopianki:** Odcinek DK7 Kraków–Myślenice (N40) również został połączony relacją ŁĄCZY_SIĘ_Z z tym samym Krakowem (N26).

Efekt w bazie Neo4j:

Dzięki spięciu obu dróg przez wspólny punkt referencyjny (Węzeł N26), algorytmy przeszukiwania grafu (np. Dijkstra/A*) mogą bez przeszkód wyznaczać trasy tranzytowe z Katowic prosto w Tatry. Fuzja zakończyła się pełnym sukcesem topologicznym.



Próba nr 2: Awaria Fuzji ("Wyspy Danych")


Błąd Semantycznego Rozproszenia

W tej próbie model stracił zdolność abstrakcji encji nadrzędnych. Zamiast stworzyć jeden węzeł dla miasta Kraków, zamknął informację geograficzną wewnątrz stringów.

- ❌ **Brak Węzła Wspólnego:** W spisie 55 węzłów nie istnieje dedykowany obiekt dla Krakowa ani Balic (Balice pojawiają się tylko jako Punkt POI N28, ale nie są połączone z DK7).
- ⚠️ **Informacja jako Tekst, nie Obiekt:** Słowo "Kraków" zostało uwięzione w nazwach odcinków: N25 ("A4 Katowice – Kraków"), N27 ("A4 Katowice – Balice"), N32 ("Zakopianka Kraków – Myślenice").

Skutek dla bazy danych:

Analiza relacji w Próbie nr 2 wykazuje ****całkowity brak połączenia**** pomiędzy podsiecią A4 a podsiecią DK7. Powstały dwie całkowicie odizolowane "wyspy danych". System komputerowy analizujący ten graf uznałby, że z autostrady A4 nie da się zjechać na Zakopiankę, co eliminuje ten graf z użytku inżynierskiego.




Fuzja Wiedzy i Entity Resolution

Integracja Wieloźródłowa

Największym sukcesem projektu była zdolność modelu do autonomicznego łączenia grafów z różnych dokumentów (A4 oraz DK7).

-  **Węzeł Kotwiczący:** Automatyczne rozpoznanie "Krakowa" jako wspólnego punktu referencyjnego.
-  **Scalenie Topologii:** Połączenie końca Autostrady A4 z początkiem Zakopianki w jedną sieć.
-  **Rezultat:** Przejście z odizolowanych "wysp danych" do zintegrowanego grafu transportowego regionu.



Ewaluacja Fuzji Wiedzy: Ziarno vs Próba 1 i 2

Cecha Strukturalna	Wzorzec (Ziarno Małopolski)	Próba nr 1 (Sukces Fuzji)	Próba nr 2 (Anomalia Strukturalna)
Liczba Węzłów	41 węzłów	53 węzły (Nad-ekstrakcja kontekstowa)	55 węzłów (Nadmierna segmentacja)
Encja Kotwicząca (Kraków)	Wyodrębniona jako osobny węzeł POI (N23)	Wyodrębniona jako osobny węzeł Miasto (N26)	Brak węzła. Rozproszona w nazwach właściwości odcinków.
Topologia Sieci	Zintegrowany graf (Jedna sieć)	Połączona spójnie	Rozbita (2 odizolowane subgrafy)
Relacje Nadrzędne	Płaskie mapowanie ciągów	A4 zdefiniowana jako kontener makro (N1)	A4 zdefiniowana jako kontener makro (N1)

Wniosek metodologiczny:
Mimo identycznego promptu i reżimu temperaturowego ($T=0.0$), wysokie zagęszczenie informacji w tekście zintegrowanym wywołało fluktuację probabilistyczną, prowadząc do dwóch skrajnie różnych strategii mapowania świata przez LLM.

Sekcja 4: Ewaluacja i Wyniki Badawcze

Analiza skuteczności, anomalie generatywne oraz fuzja danych

Determinizm vs Stochastyczność

Reżim Deterministyczny ($T=0.0$)

Ustawienie temperatury na poziomie 0.0 (Greedy Decoding) gwarantuje **100% powtarzalności struktury** przy wielokrotnych próbach.

- ✓ Stabilność składniowa JSON.
- ✓ Przewidywalność schematu danych.
- ✓ Idealne do zasilania baz produkcyjnych.

Reżim Stochastyczny ($T>0.0$)

Podniesienie temperatury stymuluje model do nieliniowej analizy, ale wprowadza **fluktuacje probabilistyczne** i błędy.

- ⚠ Ryzyko błędów ortograficznych w kluczach.
- ⚠ Niespójność identyfikatorów węzłów.
- 💡 Wyższy poziom abstrakcji (hierarchizacja).

Analiza Anomalii: Tokenization Noise

Zjawisko błędu syntaktycznego

Eksperymenty w trybie stochastycznym ujawniły błędy tokenizacji, które uniemożliwiają automatyczny import do bazy Neo4j.

```
"source": "N3",  
"target": "N9",  
"type": "ŁĄCZY SIĘ Z"
```

Błąd: Nadmiarowy token "ł" w nazwie relacji.

Rozwiązanie: Wdrożenie warstwy walidacji **Pydantic** wymuszającej zgodność ze schematem przed importem.

Ewaluacja Jakościowa: Recall i Precision

Recall (Pełność / Czułość)

Odpowiada na pytanie: *"Jaki procent rzeczywistych obiektów z tekstu udało się modelowi odnaleźć?"*

Wzór matematyczny:

$$\text{Recall} = \frac{TP}{TP + FN}$$

W naszym projekcie Recall = 100%, co oznacza całkowity brak pominąć obiektów krytycznych (mosty, wiadukty).

Precision (Precyzja)

Odpowiada na pytanie: *"Ile z obiektów wygenerowanych przez model faktycznie powinno znaleźć się w grafie?"*

Wzór matematyczny:

$$\text{Precision} = \frac{TP}{TP + FP}$$

Niższa precyzja (~77%) wynika z dodawania przez LLM węzłów kontekstowych (miasta, regiony), których nie było we wzorcowym ziarnie.

Ewaluacja Całościowa: F1-Score i Jaccard

F1-Score

Średnia harmoniczna precyzji i pełności. Jest to najbardziej obiektywna miara skuteczności modelu.

$$F_1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

Wynik **87.2%** potwierdza bardzo wysoką sprawność modelu w zadaniach inżynierii danych.

Indeks Jaccarda (Similarity)

Mierzy podobieństwo dwóch zbiorów (Wzorzec vs Wynik AI). Oblicza stosunek części wspólnej do sumy zbiorów.

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

Wartość **0.75** wskazuje na silną zbieżność topologiczną wygenerowanego grafu z rzeczywistym układem drogowym.

Metryki Jakościowe i Ilościowe

100%

Recall (Pełność)

~77%

Precision (Precyzja)

87.2%

F1-Score

0.75

Indeks Jaccarda

Interpretacja wyników: Stuprocentowa pełność (Recall) gwarantuje, że model nie pomija kluczowych danych technicznych. Niższa precyzja wynika z "nad-ekstrakcji" (tworzenia dodatkowych węzłów kontekstowych dla miast i regionów), co w kontekście budowania bazy wiedzy jest traktowane jako cecha pozytywna (Knowledge Enrichment).



Sekcja 5: Podsumowanie, Wyniki i Rekomendacje

Kompleksowy bilans projektu, analiza mocnych i słabych stron oraz wnioski
wdrożeńowe

Plusy (Silne Strony) Zaproponowanej Metody

Efektywność i Skalowalność

-  **Radykalna automatyzacja:** Skrócenie czasu ekstrakcji danych z dokumentacji technicznej z godzin (praca manualna) do sekund.
-  **Przetwarzanie masowe:** Możliwość równoległej analizy setek komunikatów i raportów bez wzrostu zapotrzebowania na zasoby ludzkie.

Głęboka Semantyczna i Fuzja

-  **Recall na poziomie 100%:** Gwarancja, że żaden kluczowy obiekt infrastruktury wymieniony w tekście nie zostanie pominięty.
-  **Autonomiczne Entity Resolution:** Zdolność do samodzielnego łączenia niezależnych dokumentów w jedną logiczną sieć grafową (np. wokół węzłów miejskich).

Minusy (Ograniczenia i Słabe Strony)

Problemy Generatywne i Składniowe

-  **Szum Tokenizacji ($T > 0.0$):** Ryzyko powstawania błędów w nazwach relacji (np. "ŁĄCZY_SIIĘ_Z"), blokujących import do bazy.
-  **Nad-ekstrakcja (False Positives):** Tworzenie nadmiarowych, ogólnych węzłów kontekstowych (np. regionów), co obniża precyzję.

Zależności Technologiczne

-  **Wrażliwość na Prompting:** Wynik końcowy jest silnie uzależniony od precyzyjnej konstrukcji instrukcji systemowych i przykładów Few-Shot.
-  **Koszty utrzymania:** Komercyjne API (OpenAI/Gemini) generują koszty proporcjonalne do wolumenu tokenów przy skomplikowanych promptach.

Kluczowe Wnioski Badawcze i Metodologiczne

-  **Prymat Pełnego Determinizmu ($T=0.0$):** Dla systemów zasilających relacyjne lub grafowe bazy danych, temperatura zero jest warunkiem koniecznym do zachowania spójności schematu.
-  **Niezbędność Walidacji Hybrydowej:** Sam model LLM nie jest systemem autonomicznym. Konieczne jest stosowanie zewnętrznych parserów (np. Pydantic, JSON Schema) jako "bezpieczników" strukturalnych.
-  **Graf jako Optymalny Model Świata:** Baza Neo4j idealnie odzwierciedla nieliniową i wielopoziomową naturę opisów infrastruktury liniowej, przewyższając klasyczne tabele relacyjne.

Rekomendacje dla Wdrożeń Przemysłowych

Architektura Systemu

Podejście Human-in-the-Loop: System powinien generować graf jako "wersję kandydacką" (wstępną), która podlega szybkiej, wizualnej akceptacji przez inżyniera kontraktu, eliminując błędy typu False Positive.

Optymalizacja i Bezpieczeństwo

Lokalne Modele LLM (Open-Source): W celu redukcji kosztów API oraz ochrony danych wrażliwych (np. niepubliczne plany przetargowe), rekomenduje się migrację na wyspecjalizowane, lokalne modele klasy Llama-3 lub Mistral dostrojone do języka polskiego.

Dziękujemy za uwagę

Automatyczne generowanie grafów infrastruktury liniowej z użyciem LLM

Prezentacja końcowa projektu badawczego | 2026

Mateusz Młynek, Michał Szczepanik
